

廖桓萱

✉ huanxuanliao@gmail.com · ☎ 15575986157 · 🌐 [Xnhyacinth](https://xnhyacinth.github.io/) · 🔗 <https://xnhyacinth.github.io/>

🎓 教育背景

中国科学院大学自动化研究所, 北京 2023 - 至今
在读博士模式识别与智能系统; 导师: [何世柱](#)、[刘康](#)

华北电力大学, 北京 2019 - 2023
学士智能科学与技术 (创新), 专业排名 1/13

💡 研究兴趣

研究面向**长程自适应智能基础模型**: 使模型有效利用持续增长的上下文, 积累可复用能力, 并在长期交互中可靠行动。

- **长上下文数据与模型协同设计**: 长文数据建设与合成、按长度和能力组织的数据配比、可扩展的预训练与中期训练、高效注意力、KV 缓存优化及模型架构, 协同提升长上下文能力、可扩展性与效率 ([LCLM-Horizon](#)、[HyCo2](#)、[Spark](#)、[ResAdapt](#))。
- **知识与持续适配**: 在不断变化的任务中获取、迁移、内化并更新知识与能力, 兼顾可塑性、能力保持和泛化 ([TAGI](#)、[AAG](#)、[NesyCD](#)、[SKIntern](#)、[SpaRTA](#))。
- **智能体学习与自我改进**: 长期记忆、长程决策, 以及从交互与反馈中学习, 推动智能体可验证地改进记忆、策略和学习过程 ([CITI](#)、[KATE](#)、[OPERATE](#)、[Distill Yourself](#)、[SLE](#))。

👨‍🔬 研究经历

腾讯 (青云计划) 北京 2026 年 7 月 - 至今
预训练数据与模型

- **长上下文预训练数据**: 设计 MRCCR 式多问答样本, 提高长历史中的答案监督密度, 并保留末尾问题; 交付 8K-512K 六档约 **186.8B token** 数据, 另构建 **10B token** 对照训练集, 核验答案位置、损失掩码和长度分布。
- **数据配方与训练分析**: 在相同训练设置下对比十组数据配方, 跟踪 8K-128K 长度档表现。10B 模型消融中, 逐答案终止并保留末尾问答的版本使 MRCCR 峰值聚合分从 **0.854** 提升至 **0.911**; 纯多问答数据在长档退化, 为配比选择提供依据。
- **稀疏架构探索**: 在匹配模型和预算下比较长文质量及 prefill/decode 开销; 发现仅降低选择器 FLOPs 无法保证端到端提速, 固定选页开销和 KV 搬运同样关键。
- **视觉-代码预训练数据**: 参与 SVG、草图到 HTML 和 CAD 数据建设, 开展图码一致性验证、跨库感知去重, 以及 Qwen3-VL-Embedding / SVGFaith-Score 分层筛选; SVG 数据集包含 **813 万条样本** (约 **41B token**)。

字节跳动北京 2025 年 6 月 - 2026 年 6 月
多模态内容理解

- **AIGC 识别业务落地**: 将高效多模态表征用于 TikTok AIGC 识别, 线上 F1 提升 **>3%**、计算量降低 **30%-50%**; 表征进一步复用于 embedding 检索。
- **输入侧分辨率自适应**: 提出 **ResAdapt** 与 **CAPO**, 在视觉编码前为每帧分配预算; 减少 **>90%** 视觉 token, 同等算力支持至多 **16×** 帧, 长视频推理相对提升 **>15%**。
- **压缩评测与架构探索**: 复现并比较视觉 token 与 KV 压缩方法, 分析精度和计算开销的取舍; 探索跳层、动态边界等高效架构。
- **长程智能体评测**: 构建 **OPERATE**, 在持续演化的模拟环境中评测智能体何时观察、干预或保持计划, 并用证据链及同 seed 反事实检查决策质量。

- **混合上下文压缩**: 提出 **HyCo₂**, 兼顾全局语义和局部证据; 七项知识型问答平均相对提升 **13.1%**, 减少约 **88.8%** 输入 token 时仍匹敌未压缩输入。
- **长上下文研究**: 作为核心贡献者参与 **LCLM-Horizon 综述**, 梳理长文数据、架构、训练和评测, 并负责 **Awesome-LCLM** 的资料整理与维护 (Curator & Maintainer)。

📖 主要文章 [完整列表]

第一作者论文优先。

[ACM TOIS'26] [Huanxuan Liao](#), Yao Xu, Shizhu He, Jun Zhao, Kang Liu. [HyCo₂: Hybrid Context Compression with Global Semantics and Local Evidence](#).

▷ 同时保留长文的全局语义与局部证据; 平均减少约 88.8% 输入 token, 七项问答平均相对提升 13.1%。

[arXiv'26] [Huanxuan Liao](#), Zhongtao Jiang, Yupu Hao, Yuqiao Tan, Shizhu He, Ben Wang, Jun Zhao, Kun Xu, Kang Liu. [ResAdapt: Adaptive Resolution for Efficient Multimodal Reasoning](#).

▷ 在编码前按帧分配视觉预算; 减少 >90% token, 同等算力可处理至多 16× 帧, 并改善长视频推理。

[ACL'26] [Huanxuan Liao](#), Shizhu He, Yupu Hao, Yequan Wang, Wenhao Teng, Xiangwen Liao, Jun Zhao, Kang Liu. [Spectral Disentanglement: Rank-Aware Task Adaptation for Rehearsal-free Continual Learning in LLMs](#).

▷ 将共享知识与任务专有知识放入不同参数子空间, 减少无回放持续学习中的任务干扰。

[AAAI'26] [Huanxuan Liao](#), Yixing Xu, Shizhu He, Guanchen Li, Xuanwu Yin, Dong Li, Emad Barsoum, Jun Zhao, Kang Liu. [Spark: Query-Aware Unstructured Sparsity with Recoverable KV Cache Channel Pruning](#).

▷ 按查询选择并恢复重要 KV 通道; 可与时序压缩叠加, 降低长文缓存占用。

[AAAI'25] [Huanxuan Liao](#), Shizhu He, Yao Xu, Yuanzhe Zhang, Kang Liu, Jun Zhao. [Neural-Symbolic Collaborative Distillation: Advancing Small Language Models for Complex Reasoning Tasks](#).

▷ 把通用能力蒸馏进小模型、专业知识存入符号库, 让小模型更好地完成复杂推理。

[COLING'25] [Huanxuan Liao](#), Shizhu He, Yupu Hao, Xiang Li, Yuanzhe Zhang, Jun Zhao, Kang Liu. [SKIntern: Internalizing Symbolic Knowledge for Distilling Better CoT Capabilities into Small Language Models](#).

▷ 循序内化符号知识与示例, 推理时只输入问题, 减少提示和计算开销。

[COLING'25] [Huanxuan Liao](#), Shizhu He, Yao Xu, Yuanzhe Zhang, Shengping Liu, Kang Liu, Jun Zhao. [Awakening Augmented Generation: Learning to Awaken Internal Knowledge of Large Language Models for Question Answering](#).

▷ 生成辅助上下文与任务适配器, 在不检索外部资料时更好地调用模型已有知识。

[NeurIPS'24] [Huanxuan Liao](#), Shizhu He, Yao Xu, Yuanzhe Zhang, Yanchao Hao, Shengping Liu, Kang Liu, Jun Zhao. [From Instance Training to Instruction Learning: Task Adapters Generation from Instructions](#).

▷ 由任务指令直接生成适配器, 减少逐任务训练的开销, 并保持实例训练的效果。

[arXiv'25] Jiaheng Liu, Dawei Zhu, Zhiqi Bai, Yancheng He, [Huanxuan Liao](#), et al. [A Comprehensive Survey on Long Context Language Modeling. \(Core Contributor\)](#)

▷ 系统梳理长上下文训练数据、架构、部署与评测, 为长文基模研究提供路线图。

♡ 获奖情况

国家奖学金 ×3
北京市优秀毕业生

2021 / 2022 / 2025
2023.06

💡 专业服务

会议审稿: ACL ARR 2024–2026. NeurIPS 2025–2026. ICML 2026. COLM 2026. ICLR 2025–2026. AAAI 2026.

开源社区: **Awesome-LCLM**: 资料整理与维护 (Curator & Maintainer); **NVIDIA/kvpress**: 贡献者; **Distill Yourself**: 核心逻辑与代码贡献者。