

廖桓萱

✉ huanxuanliao@gmail.com · ☎ 15575986157 · 🌐 Xnhyacinth · 🌐 https://xnhyacinth.github.io/

🎓 教育背景

中国科学院大学自动化研究所, 北京 2023 – 至今
在读博士 模式识别, 自动化研究所模式识别国家重点实验室, 导师何世柱 and 刘康

华北电力大学, 北京 2019 – 2023
学士 智能科学与技术 (创新), 1/13

💡 研究兴趣

- 长上下文与多模态效率 – 压缩与输入侧预算分配, 落地长序列/多模态推理:
 - 社区与综述: Awesome-LCLM (Stars > 2.2K); LCLM Survey (arXiv 2025, 核心贡献者)
 - 上下文 / KV 压缩: HyCo2 (arXiv 2025), Spark (AAAI 2026)
 - 参数化 RAG: DyPRAG (arXiv 2025)
 - 多模态效率: ResAdapt (arXiv 2026)
- 高效推理与策略优化 – 成本约束下的知识激活、蒸馏与迁移:
 - 指令 / 适配器: TAGI (NeurIPS 2024), SHIP (ACL 2026 Main)
 - 知识激活与蒸馏: AAG (COLING 2025), SKIntern (COLING 2025), NesycD (AAAI 2025)
 - 持续适应: SpaRTA (ACL 2026 Main), PaRSP (ACL 2026 Main)
 - 策略优化: BuPO (arXiv 2025), CAPO
- 智能体系统与工具学习 – 可靠工具使用、评测与智能体记忆:
 - 工具学习 / 评测 / RL: CITI (AAAI 2025), ETAPP (ACL 2025 Main), KATE (ACL 2026 Findings), Tool-RL-Box (FAGEN@ICML 2026)
 - 智能体记忆与偏好蒸馏: Distill Yourself

📖 主要文章 [完整列表]

(* stands for equal contribution; Listed in reverse chronological order.)

- [Huanxuan Liao](#), Zhongtao Jiang, Yupu Hao, Yuqiao Tan, Shizhu He, Ben Wang, Jun Zhao, Kun Xu, Kang Liu. ResAdapt: Adaptive Resolution for Efficient Multimodal Reasoning. (arXiv 2026)

▷ 针对编码后压缩过晚、算力已花完的问题, 在输入侧按帧自适应分配分辨率预算, 并以 CAPO 训练非可微分配器; 丢弃 >90% 视觉 token, 同等算力可处理至多 16× 帧, 长视频推理相对提升 >15%。

- [Huanxuan Liao](#), Shizhu He, Yupu Hao, Yequan Wang, Wenhao Teng, Xiangwen Liao, Jun Zhao, Kang Liu. Spectral Disentanglement: Rank-Aware Task Adaptation for Rehearsal-free Continual Learning in LLMs. (ACL 2026 Main, CCF-A)

▷ 针对 LoRA 单一秩约束导致的稳定性-可塑性困境, 将知识解耦至低秩共享与高秩专属正交子空间, 并以上下文感知路由融合; 无回放持续学习中显著降低任务干扰, 并提升未见任务零样本泛化。

- [Huanxuan Liao](#), Yixing Xu, Shizhu He, Guanchen Li, Xuanwu Yin, Dong Li, Emad Barsoum, Jun Zhao, Kang Liu. Spark: Query-Aware Unstructured Sparsity with Recoverable KV Cache Channel Pruning. (AAAI 2026, CCF-A)

▷ 发现 KV 通道重要性随查询与位置剧烈变化, 提出训练无关的查询感知通道剪枝, 并在注意力计算时动态恢复; 与时序压缩正交可叠加, 同等长度较 eviction 再省 >30% KV, 80% 剪枝时性能退化 <5%。

- [Huanxuan Liao](#), Shizhu He, Yao Xu, Yuanzhe Zhang, Kang Liu, Jun Zhao. Neural-Symbolic Collaborative Distillation: Advancing Small Language Models for Complex Reasoning Tasks. (AAAI 2025, CCF-A)

▷ 解耦蒸馏: 将 LLM 通用能力写入参数化小模型, 稀缺专业知识写入可解释符号知识库; 使 LLaMA3-8B / Qwen2-7B 超越 GPT-3.5-turbo, 并接近参数量约 9× 的 LLaMA3-70B。

- [Huanxuan Liao](#), Shizhu He, Yupu Hao, Xiang Li, Yuanzhe Zhang, Jun Zhao, Kang Liu. SKIntern: Internalizing Symbolic Knowledge for Distilling Better CoT Capabilities into Small Language Models. (COLING 2025, CCF-B)

▷ 以课程学习与线性衰减日程渐进内化符号知识与 few-shot, 推理时仅依赖问题本身; 较 SOTA 提升 >5%, 推理 FLOPs 最高降低约 4x, 并改善 ID/OOD 表现。

- [Huanxuan Liao](#), Shizhu He, Yao Xu, Yuanzhe Zhang, Kang Liu, Shengping Liu, Jun Zhao. Awakening Augmented Generation: Learning to Awaken Internal Knowledge of Large Language Models for Question Answering. (COLING 2025, CCF-B)

▷ 无需外部检索: 显式生成压缩合成文档作符号上下文, 隐式用超网络生成适配器作参数上下文, 双路径唤醒 LLM 内部知识; 在开放域、闭卷与 OOD 问答上均有显著优势。

- [Huanxuan Liao](#), Shizhu He, Yao Xu, Yuanzhe Zhang, Yanchao Hao, Shengping Liu, Kang Liu, Jun Zhao. From Instance Training to Instruction Learning: Task Adapters Generation from Instructions. (NeurIPS 2024, CCF-A)

▷ 由任务指令经超网络直接生成任务适配器, 并通过标签/logits/参数蒸馏对齐实例训练模型; 在 Super-Natural Instructions 与 P3 上匹配或超过元学习与其他超网络方法, 同时显著降低计算开销。

- [Huanxuan Liao](#), Shizhu He, Yupu Hao, Jun Zhao, Kang Liu. Beyond Hard and Soft: Hybrid Context Compression for Balancing Local and Global Information Retention. (arXiv 2025)

▷ 混合适配器保留软全局语义, 分类器硬剪枝保留局部证据, 并以改写/补全预训练稳定两路耦合; 七项知识型 QA 平均相对提升 13.1%, 平均削减约 88.8% token 仍匹敌未压缩。

- Jiaheng Liu, Dawei Zhu, Zhiqi Bai, Yancheng He, [Huanxuan Liao](#), et al. A Comprehensive Survey on Long Context Language Modeling. (arXiv 2025, Core Contributor)

▷ 长上下文语言建模综述 (核心贡献者): 系统梳理有效/高效 LCLM 的数据与架构、训练部署基础设施, 以及评测、行为分析与应用前景。

🧑 实习/项目经历

腾讯 (青云计划) 北京

2026 年 4 月 - 2026 年 8 月

实习 实习生 (预训练)

- 稀疏注意力架构探索: 提出 **ROAM**, 在 Stage-1 选择/路由开销已逼近甚至超过 Stage-2 attention 的设定下, 以低频 Future Pool + 高频 Pool 内精排替代逐 token 全局路由, 并完成 HBM residency 与 direct-paged Stage-2 的算法-系统协同实现与评测, 降低全局选择与 KV 搬运开销。
- 视觉-代码数据合成: 搭建 games / SVG / sketch2code 等视觉生成代码的合成与转换管线, 覆盖许可分级采集与行为验收, 服务多模态预训练数据构建。
- 多模态错误 Agent: 构建多模态错误 Agent, 以可执行断言驱动 Detect → 首因定位 → 局部修复 → 复验, 定位并修复合成数据中的过程级静默错误; 硬层召回 **0.798**, 受控 SVG 图反事实 Acc@5 **1.00** (vs 平坦重放 0.33), 服务预训练数据质检与合成回流。

字节跳动北京

2025 年 6 月 - 2026 年 3 月

实习 研究型实习生 (高效多模态理解)

- **AIGC 识别业务落地**: 将高效多模态方法落地 AIGC 识别业务, 线上 F1 提升 >3%、计算量节省 30%-50%, 并拓展至 embedding 检索与表征复用。
- **输入侧分辨率自适应**: 提出 **ResAdapt + CAPO**, 在编码前按帧分配视觉预算; 丢弃 >90% 视觉 token, 同等算力支持至多 16x 帧, 长视频推理相对提升 >15%。
- **压缩评测与架构探索**: 复现对比多模态视觉 token / KV 压缩方法, 并探索跳层、动态边界等高效架构, 拓宽效率-精度 Pareto 边界。
- **复杂调度工作 Benchmark**: 构建 DT-Sched-Bench, 评测 LLM 长程自主调度能力: 原生模拟器自主演进环境, Agent 自主决定观察、干预或维持计划; 任务经来源锁定与消费证明过滤, 并以证据链与同 seed 反事实评估决策质量。

蚂蚁集团北京

2025 年 2 月 - 2025 年 5 月

实习 研究型实习生 (长上下文)

- 混合上下文压缩: 提出 **HyCo2** (软全局语义 + 硬局部剪枝), 知识型 QA 平均相对提升 **13.1%**, token 削减约 **88.8%** 且性能匹敌未压缩。
- 长上下文综述: 作为核心贡献者完成 LCLM 综述 (数据 / 架构 / 评测), 并维护 Awesome 长上下文仓库。

♡ 获奖情况

国家奖学金 ×3
北京市优秀毕业生

2021 / 2022 / 2025
2023.06

💡 专业服务

extbf 会议审稿: ACL ARR 2024–2026. NeurIPS 2025–2026. ICML 2026. COLM 2026. ICLR 2025–2026. AAAI 2026.

开源社区: Awesome-LLM-Long-Context-Modeling (GitHub Stars > 2.2K); LCLM-Horizon 综述 (核心贡献者); NVIDIA/kvpress (贡献者); Distill Yourself (智能体记忆与偏好蒸馏)。